IUT de Paris - Rives de Seine
Université Paris Cité

ARTHUR SIMON
BUT SD – 2e année EMS

RAPPORT DE STAGE

14/04/2024 – 24/06/2025

Identification des valeurs anormales dans le suivi biologique des sportifs de haut niveau

Institut National du Sport, de l'Expertise et de la Performance

Service : UDNI

11 avenue du Tremblay, 75012 Paris

Maître de stage : Geoffroy Berthelot

Tuteur de stage : Jérôme Dedecker

INSEP

Sommaire

Remerciements **4**
I. Introduction **5**
II. Contexte du stage **6**
II.1. Présentation de l'INSEP 6
II.2. Missions et structure de l'INSEP **7**
II.3. Présentation de l'UDNI 9
III. Cartographie de l'architecture des données **10**
III.1. Circuit et présentation des données 10
III.2. Environnement technique 11
IV. Mission **12**
IV.1. Contexte et objectifs 12
IV.2. Déroulement de la mission 13
IV.3. Résultats obtenus 21
IV.4. Conclusion technique 23
V. Conclusion générale **24**
VI. Bibliographie **25**
VII. Lexique **26**
VIII. Annexes **30**
IX. Démarche portfolio **31**

Remerciements

Je tiens tout d'abord à remercier chaleureusement l'INSEP (Institut National du Sport, de l'Expertise et de la Performance) de m'avoir accueilli pour la réalisation de ce stage. Ce fut une expérience extrêmement enrichissante au sein de cette institution reconnue.

Je souhaite également exprimer ma gratitude envers mes professeurs, dont les enseignements tout au long de l'année m'ont permis de développer les compétences nécessaires pour mener à bien ce stage.

Je remercie Jérôme Dedecker et Guillaume Saulière, pour leurs conseils et leur accompagnement lors de certaines étapes de mon projet.

Enfin, je tiens à adresser mes remerciements les plus sincères à Geoffroy Berthelot, chercheur à l'INSEP, qui a sélectionné ma candidature pour ce stage et m'a fait confiance tout au long de ma mission. Son écoute, sa disponibilité et sa gentillesse ont rendu ce stage très agréable. J'ai beaucoup apprécié nos échanges, et sa guidance m'a permis d'enrichir mes connaissances et de progresser.

I. Introduction

Dans le cadre de la **deuxième année de ma formation en sciences des données à l'IUT Paris Rives de Seine**, j'ai eu l'opportunité d'effectuer un stage de dix semaines à, l'Institut National du Sport, de l'Expertise et de la Performance. **L'INSEP** est un centre de référence pour la préparation des athlètes de haut niveau. Ce stage, réalisé **entre avril et juin 2025**, m'a permis de **mettre en pratique les compétences acquises** au cours de mes études tout en m'immergeant dans un environnement où la science des données joue un rôle central dans le suivi et la performance des sportifs.

Le choix de l'INSEP pour ce stage s'inscrit dans mon souhait d'allier mes compétences en analyse de données à ma passion pour le sport. L'opportunité de rejoindre cet institut m'a été présentée par Geoffroy Berthelot, enseignant vacataire à l'IUT, avec qui j'avais déjà collaboré sur un projet portant sur la relation entre l'âge et la performance sportive. Après cette première collaboration, j'ai été particulièrement intéressé par le projet proposé à l'INSEP, qui consistait à analyser des données médicales d'athlètes, un domaine où la science des données joue un rôle central dans l'optimisation des performances. Cette expérience m'a permis de découvrir un environnement où l'analyse de données a une application concrète et directe dans la gestion de la santé des sportifs.

Lors de ce stage, j'ai été chargé **d'appliquer un package R développé par les chercheurs de l'INSEP** pour détecter des valeurs anormales dans des données longitudinales. Ainsi, ma mission était de comparer les résultats obtenus avec d'autres méthodes statistiques existantes, dans le but d'évaluer l'efficacité du package. Au préalable, durant les deux premières semaines, mon travail consistait en la lecture d'anciens articles ainsi qu'en la prise en main du package.

La problématique principale résidait donc dans **l'adaptation des méthodes statistiques aux spécificités des données** biomédicales des sportifs : les résultats convergent ou divergent-ils entre les différentes méthodes ?

Figure 1 : Vue aérienne INSEP (1)

II. Contexte du stage

II.1. Présentation de l'INSEP

L'Institut National du Sport, de l'Expertise et de la Performance (INSEP) est un établissement public français de référence dédié au sport de haut niveau. Fondé en 1975 et situé au cœur du bois de Vincennes à Paris, l'INSEP joue un rôle central dans la formation, la recherche et la préparation des athlètes d'élite en France.

Histoire de l'INSEP

L'origine de l'INSEP remonte à l'après-guerre : l'Institut National des Sports est créé sur le site du Bois de Vincennes, un terrain déjà riche d'histoire sportive en 1945. Puis, en 1955, l'École normale supérieure d'éducation physique (ENSEP) s'installe dans un centre commun avec l'INS, « les établissements de Joinville.

Après la performance catastrophique de la France aux Jeux olympiques de Rome en 1960, l'opinion publique est déçue et une volonté politique de faire rayonner la France dans le monde du sport naît.

Ainsi, en octobre 1965, le Général de Gaulle inaugure la halle Maigrot située au centre de ce qui deviendra l'INSEP. À l'époque, c'est la plus grande salle couverte d'Europe.

L'INSEP est officiellement créé en 1975. Au cours des années suivantes, l'INSEP gagne en réputation, reconnu comme la structure de référence du sport de haut niveau en France. L'INSEP se distingue par son rayonnement européen et international, grâce aux performances remarquables de ses athlètes dans une multitude de disciplines sportives.

Activités actuelles

Aujourd'hui, l'INSEP est bien plus qu'un simple centre d'entraînement. C'est un écosystème où se côtoient sportifs de haut niveau, chercheurs, étudiants et professionnels spécialisés, tous unis par un objectif commun : promouvoir l'excellence sportive en France. L'INSEP fournit des infrastructures de pointe, des programmes de formation spécialisés, et une expertise avancée dans des domaines tels que la performance sportive ou la médecine du sport. Chaque jour, 27 disciplines sportives s'entraînent au sein de l'INSEP.

Figure 2 : Photographie du bâtiment de l'INSEP (2)

II.2. Mission et structure de l'INSEP

Sa mission principale consiste à préparer et à accompagner les sportifs de haut niveau tout en assurant la formation des cadres supérieurs du domaine sportif.

Pour remplir ses objectifs, l'INSEP met à disposition des moyens exceptionnels : des infrastructures modernes, un campus immense, des technologies de pointe et une expertise reconnue dans divers domaines tels que la médecine sportive, la performance, la recherche, et la formation.

Ce cadre est conçu pour offrir aux athlètes et aux professionnels du sport un environnement optimal favorisant l'épanouissement personnel et la quête de résultats de haut niveau.

Parmi les infrastructures, se trouvent une piscine olympique, plusieurs gymnases et terrains de sport, et des infrastructures administratives, il n'y a aucun autre équivalent en France d'un tel campus, reproduit ci-dessous (le service dans lequel je suis intervenu se trouve dans le bâtiment C).

Figure 3 : Infrastructures de l'INSEP

L'INSEP est organisé en plusieurs pôles d'expertise, chacun ayant une mission spécifique. Parmi eux :

- **Le pôle médical**, qui veille à la santé, au suivi et à la récupération des athlètes ;
- **Le pôle formation**, qui accompagne les athlètes dans leur double projet alliant carrière sportive et développement académique ou professionnel ;
- **Le pôle haut niveau**, dédié à l'entraînement, à l'analyse et à l'optimisation des performances ;
- **Le pôle performance**, qui travaille à l'innovation et à l'élaboration de stratégies gagnantes pour les compétitions internationales.

Grâce à cette organisation, l'INSEP contribue à renforcer la position de la France dans le sport mondial en formants des athlètes, des chercheurs et des entraîneurs au plus haut niveau de leur domaine.

Figure 4 : Organigramme fonctionnel de l'INSEP

L'organigramme nominatif est aussi disponible en cliquant ici.

II.3. Présentation de l'UDNI

L'Unité du Développement du Numérique et de l'Innovation (UDNI) de l'INSEP, pôle dans lequel j'ai effectué ce stage, est un département clé qui se consacre à l'amélioration des performances des athlètes de haut niveau. Elle se concentre sur le développement de solutions numériques innovantes, allant des applications mobiles à la réalité virtuelle et augmentée, en passant par la gestion et l'analyse des données de performance.

L'UDNI travaille en étroite collaboration avec d'autres départements de l'INSEP ainsi qu'avec des partenaires externes pour créer des outils adaptés aux besoins spécifiques des athlètes et des équipes médicales. Parmi les projets clés, l'UDNI met en œuvre des systèmes de gestion des données et de suivi médical, notamment à travers des technologies comme le Data Lake et des outils d'analyse tels que Tableau Software.

Au sein de cette unité, mon maître de stage, fait partie de l'équipe de développement. Il participe activement à la conception et à l'optimisation des outils utilisés pour analyser les données médicales et les performances des athlètes, contribuant ainsi à la prise de décision éclairée.

III. Cartographie de l'architecture des données

III.1. Circuit et présentation des données

Les fichiers à ma disposition s'inscrivent dans un **circuit de données** allant de la production médicale (collecte biologique en contexte sportif) jusqu'à leur exploitation statistique.
Elles ont été collectées dans le cadre de bilans biologiques réguliers, puis les médecins les ont ensuite transmises à l'UDNI. Après une première phase de nettoyage et de restructuration des bases de données, celles-ci m'ont finalement été envoyées par mon tuteur sous forme de fichiers texte.

Ces données proviennent de deux bases issues de suivis médicaux réalisés sur des populations sportives de haut niveau. Une première base concerne des joueurs de football professionnels, et la seconde, des cyclistes issus de plusieurs disciplines. Les fichiers initiaux m'ont été transmis au format .txt, puis convertis en .csv et .xlsx pour faciliter leur traitement dans R.

La base **football** regroupe environ **109 000 prélèvements biologiques** collectés entre 2006 et 2012 sur **3 930 joueurs** évoluant en Ligue 1 et Ligue 2. Deux campagnes de prélèvements étaient réalisées chaque année, en juillet/août et janvier/mars. Un incident technique a conduit à la perte des données de la campagne de juillet/août 2009. Pour assurer la cohérence des séries analysées, seuls les joueurs disposant d'au moins 3 mesures ont été conservés.

Les biomarqueurs suivis dans cette base sont au nombre de cinq :

- **GR** (Globules rouges / érythrocytes) : Unité : millions de cellules par litre (T/L).
- **Hb** (Hémoglobine) : Unité : grammes par litre (g/L).
- **Ht** (Hématocrite) : Unité : pourcentage (%).
- **Ferritine** : Unité : micromoles par litre (µmol/L).
- **Serum_iron** (Fer sérique) : Unité : micromoles par litre (µmol/L).

La base **cyclisme**, légèrement plus volumineuse, contient environ **119 000 prélèvements biologiques** réalisés sur **1 683 cyclistes**. Elle comporte de nombreuses variables contextuelles dont notamment la classe d'âge, la discipline (BMX, cyclocross, poursuite, route, vitesse, VTTD, VTTT, VTTXC), le statut (amateur ou professionnel), ainsi que les informations temporelles (jour, mois, année).

Cette base contient un total de **12 biomarqueurs**, parmi lesquels :

- **GR** (Globules rouges / érythrocytes) : Unité : millions de cellules par litre (T/L).
- **Hb** (Hémoglobine) : Unité : grammes par litre (g/L).
- **Ht** (Hématocrite) : Unité : pourcentage (%).
- **Ferritine :** Unité : micromoles par litre (µmol/L).
- **Reticulocytes** : Unité : giga par litre (G/L).
- **ReticulP**: Unité : giga par litre (G/L).
- **HROFF** (Off-Score) : indice composite sans unité
- **IGF1** (Insulin-like Growth Factor 1) : Unité : nanogrammes par millilitre (ng/mL).
- **Cortisol** : Unité : nanomoles par litre (nmol/L).
- **Testostérone** : Unité : nanomoles par litre (nmol/L).
- **Ostéocalcine** : Unité : nanogrammes par millilitre (ng/mL).

- **DHEA** (Déhydroépiandrostérone) : Unité : nanomoles par litre (nmol/L).

Cette diversité permet une analyse plus approfondie des états physiologiques et hormonaux des athlètes. Cependant, pour les deux bases, le format des données (une ligne par individu) et la présence de valeurs vides pour certains biomarqueurs ont nécessité une réadaptation préalable rigoureuse. Ainsi, j'ai effectué des transformations pour obtenir une base contenant une ligne par prélèvement, et donc que chaque ligne des tableaux de données soit exploitable.

III.2. Environnement technique

L'ensemble des traitements a été effectué dans l'environnement **R**, à l'aide de l'interface **RStudio**. Le cœur de l'analyse repose sur l'utilisation du package **Devian-LM**, développé en interne à l'INSEP, notamment par **Guillaume Saulière**, avec qui j'ai pu échanger une fois le package exploré en profondeur. Cet échange m'a permis de clarifier plusieurs points essentiels : le fonctionnement exact du package, la méthode de calcul des seuils, l'interprétation des différentes valeurs retournées (résidus, seuils, indicateurs d'anomalies), les types de graphiques générés, ainsi que les perspectives d'évolution vers des analyses multivariées, encore non implémentées à ce stade.

Tout au long du stage, j'ai également pu m'appuyer sur des échanges réguliers avec **Geoffroy Berthelot**, mon maître de stage. Il m'a guidé sur les jeux de données à utiliser, sur les attentes pratiques en termes de résultats, et sur les aspects organisationnels de l'analyse. Ces discussions m'ont permis de faire des choix techniques cohérents avec les objectifs de l'UDNI et d'adapter mes traitements aux contraintes de données réelles.

En complément, j'ai pu participer à des réunions avec **Jérôme Dedecker**, professeur de mathématiques, pour discuter plus en profondeur de la validité statistique des approches employées. Cela m'a permis de renforcer ma compréhension des hypothèses sous-jacentes aux modèles, de mieux appréhender le fonctionnement des simulations, et de prendre du recul sur les limites et la fiabilité des résultats obtenus avec Devian-LM.

Pour concevoir mon code, j'ai mobilisé plusieurs bibliothèques R : *dplyr* pour les manipulations de données, *readr* et *readxl* pour l'importation, *ggplot2* pour produire les visualisations, *tidyr* pour réorganiser les données et *lubridate* pour gérer les dates. Ces outils m'ont permis de structurer un environnement de travail clair, efficace et reproductible.

Enfin, pour garantir la performance des analyses, certaines exécutions ont été lancées sur les **serveurs de calcul de l'INSEP**. Cela m'a permis **d'augmenter le nombre de simulations à plusieurs millions**, ce qui améliore considérablement la stabilité des seuils obtenus et renforce la fiabilité des détections.

Deux documents m'ont également été transmis pour cadrer mon travail : un **article scientifique** décrivant les méthodes antérieures basées sur les Z scores, et un **compte rendu d'analyse de l'UDNI** détaillant les résultats obtenus jusqu'ici et les limites identifiées (voir bibliographie). Ces supports ont orienté mes décisions techniques et m'ont servi de point de comparaison avec les sorties produites par Devian-LM.

IV. Mission

IV.1. Contexte, objectifs et livrables

Le principal objectif de mon stage était d'**identifier les séquences anormales** dans les données biomédicales des footballeurs et des cyclistes de haut niveau, en utilisant des données issues de bilans médicaux réguliers. Cette analyse visait à détecter des anomalies biologiques pouvant être liées à des **problèmes de santé**, du **surmenage** ou des **signes potentiels de dopage**, afin d'améliorer le suivi médical et la performance des athlètes.

Une mission centrale de mon travail était d'**appliquer le package Devian-LM** [1] développé à l'INSEP pour vérifier s'il générait des **résultats cohérents**. L'objectif était de tester son efficacité dans la détection d'anomalies biologiques et d'évaluer la fiabilité avec trois différentes méthodes. En parallèle, un des objectifs à plus long terme était de pouvoir **automatiser** cette détection des anomalies et d'étendre cette méthode à d'autres jeux de données, facilitant ainsi l'analyse à grande échelle.

Le **livrable** principal de mon stage était le **code R** développé pour appliquer le **package Devian-LM** à trois modèles différents, chacun avec un design spécifique [1]. Ce code permet de détecter automatiquement les anomalies dans les données biomédicales, de générer des **graphiques** pour visualiser les anomalies détectées et de créer des **fichiers CSV** contenant les **valeurs anormales** pour chaque individu et biomarqueur.
En complément du **code** développé, un **rapport détaillé** a été rédigé pour documenter l'ensemble des travaux réalisés.

Enfin, j'ai préparé un **support** pour **présenter mes résultats** devant les professionnels de l'INSEP, en particulier devant le chargé de projets scientifiques (coté médical) et l'adjoint au pôle performance.

Ce support a permis de mettre en valeur les résultats de mon travail, de détailler la méthodologie appliquée, et de présenter l'**outil développé**. La présentation a aussi permis de **discuter des applications concrètes** de mon travail dans le suivi des athlètes, ainsi que des perspectives d'amélioration pour l'utilisation future de l'outil dans différents contextes sportifs.

L'objectif global de mon stage était de mettre en place un **outil d'analyse robuste**, capable de détecter des anomalies dans différents contextes et de l'adapter à d'autres jeux de données dans le futur.

[1] Berthelot G., Saulière, G., Dedecker, J. DEViaN-LM: An R Package for Detecting Abnormal Values in the Gaussian Linear Model.

IV.2. Déroulement de la mission

Pour commencer l'analyse, j'ai effectué des analyses visant à identifier la population et notamment celle des cyclistes. En effet, cette dernière est la seule qui contient des variables contextuelles telles que la tranche d'âge, la discipline (BMX, Route, …), ou encore le statut (amateur, professionnel) **(Figure 5).**

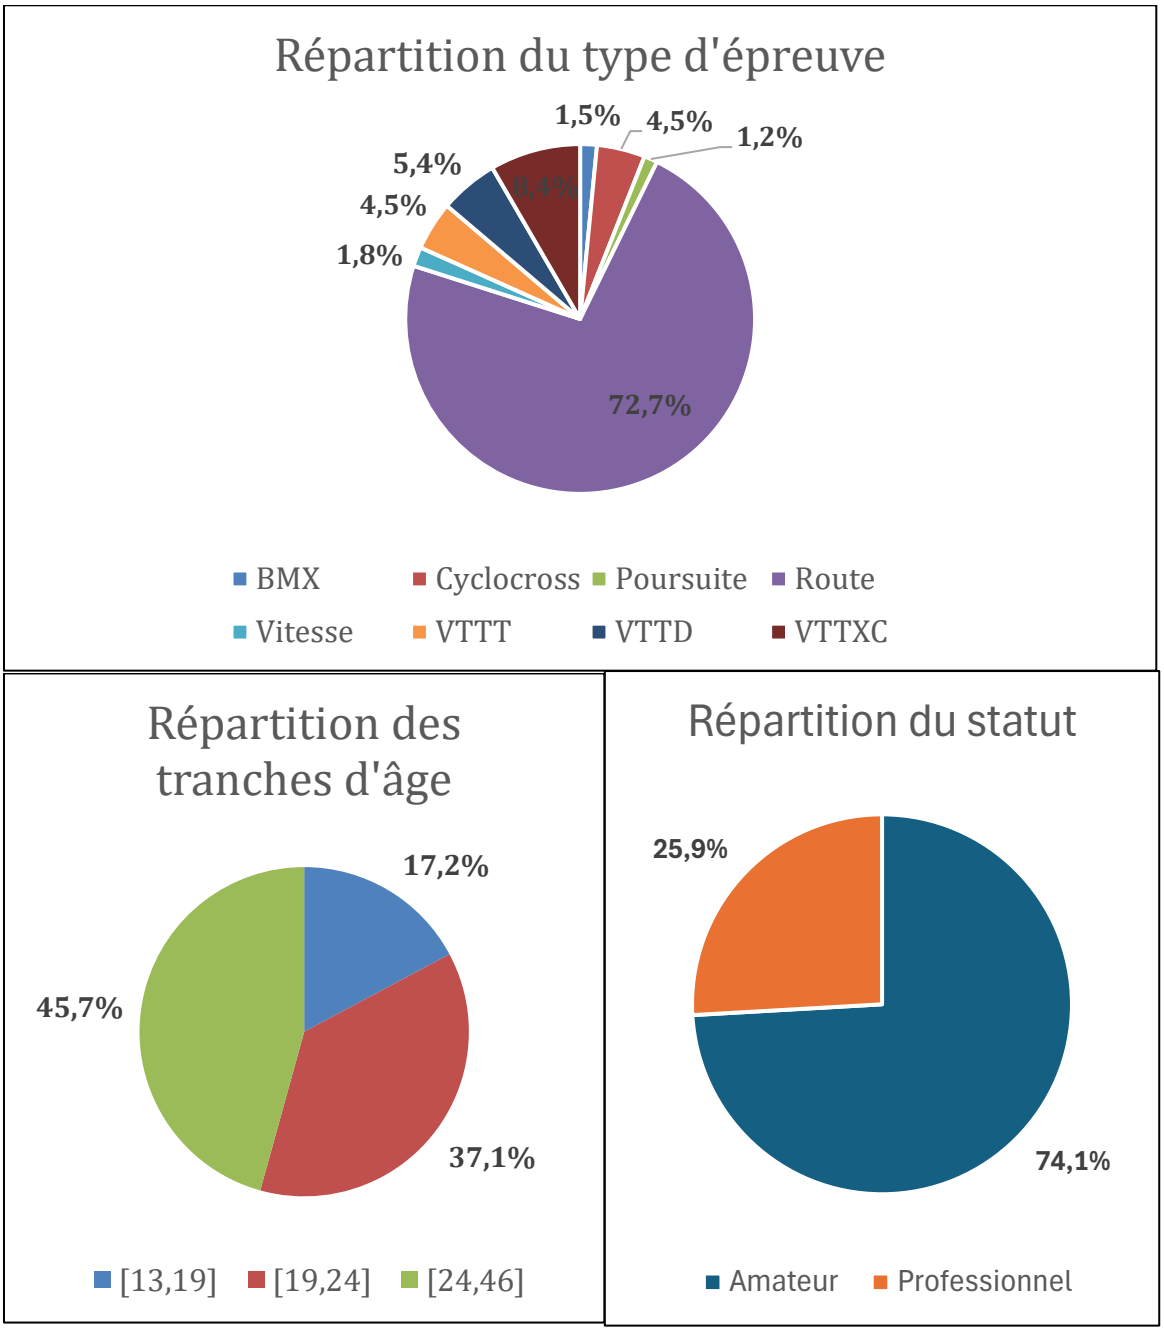

Figure 5 : répartition de la population par variables.

Les graphiques ci-dessus révèlent que le profil le plus représenté dans la base cyclisme est celui d'un amateur âgé de 24 à 46 ans, pratiquant la discipline de la route
Ce profil se distingue par une forte majorité dans les trois catégories analysées : 72,7 % pour la route, 45,7 % pour la tranche d'âge 24–46 ans, et 74,1 % pour le statut amateur.

Il a fallu ensuite effectuer le **point essentiel** de ce travail : **appliquer le package** DevianLM à ces jeux de données. DevianLM est une extension du Zscore au **cadre Gaussien**. En particulier, on peut spécifier un **design de modèle** à DevianLM, de manière identique à la fonction lm() sous R. Nous nous sommes donc penchés sur trois designs, ou modèles statistiques, distincts pour détecter les valeurs anormales dans les données :
:

- **Modèle A** : Ce modèle est un **modèle de base**, où l'on considère uniquement l'intercept, sans variables explicatives. La formule du modèle est la suivante :

$$y_i = \beta_0 + \varepsilon_i$$

y_i: représente la valeur observée du biomarqueur pour l'individu i au moment du prélèvement.
β_0: est l'intercept du modèle, qui représente la valeur moyenne du biomarqueur du sous-groupe (biomarqueur + individu) et qui sert donc de ligne de base individuelle.
ε_i: est l'erreur du modèle pour l'observation i, représentant la déviation de la valeur observée par rapport à la moyenne.

Ce modèle sert de point de référence pour les autres approches et est appliqué aux individus ayant **au moins 3 prélèvements (Figure 6).** Pour calculer ce nombre de prélèvement minimum, on sait que : n > p+1, avec p le nombre de colonne de notre design (ici une seule colonne existe : une colonne de 1 pour l'intercept)
Donc, on retrouve bien : n <= 3.

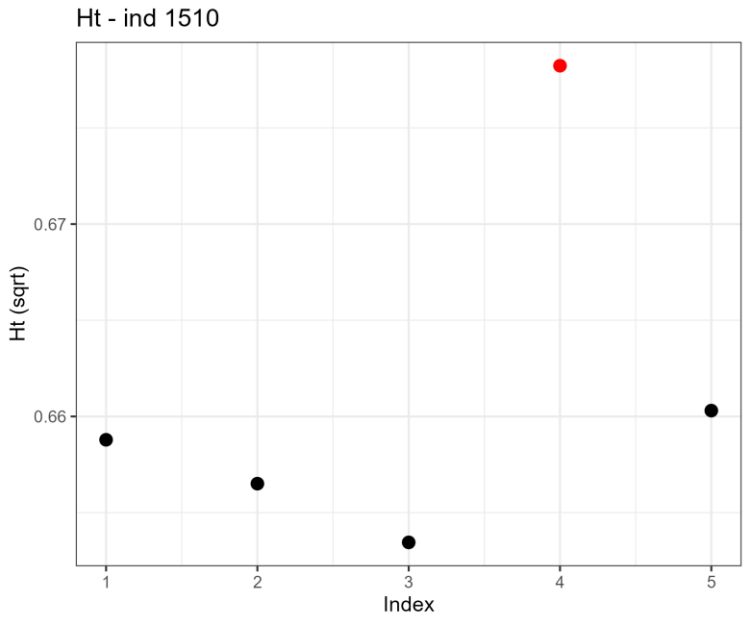

Figure 6 : Exemple de réalisation de DevianLM pour le modèle A

- **Modèle B** : Ce modèle inclut une variable saisonnière binaire, distinguant entre **été** (0) et **hiver** (1). La formule du modèle est :

$$y = \beta_0 + \beta_1 . x_{\text{summer}} + \varepsilon$$

β_0 : est l'intercept, il représente la valeur moyenne du biomarqueur du sous-groupe (biomarqueur + individu) lorsque saison = 0, c'est-à-dire en hiver selon x_{summer}. Il sert de ligne de base individuelle du modèle.
β_1: est le coefficient associé à la variable saisonnière, il mesure l'effet du passage de l'hiver à l'été
x_{summer}: est une variable binaire qui prend la valeur 0 pour l'été et 1 pour l'hiver, pour chaque prélèvement.

Ce modèle est utilisé pour les individus ayant **au moins 4 prélèvements** (ici p=2), avec **2 prélèvements minimum pour chaque saison (Figure 7).**

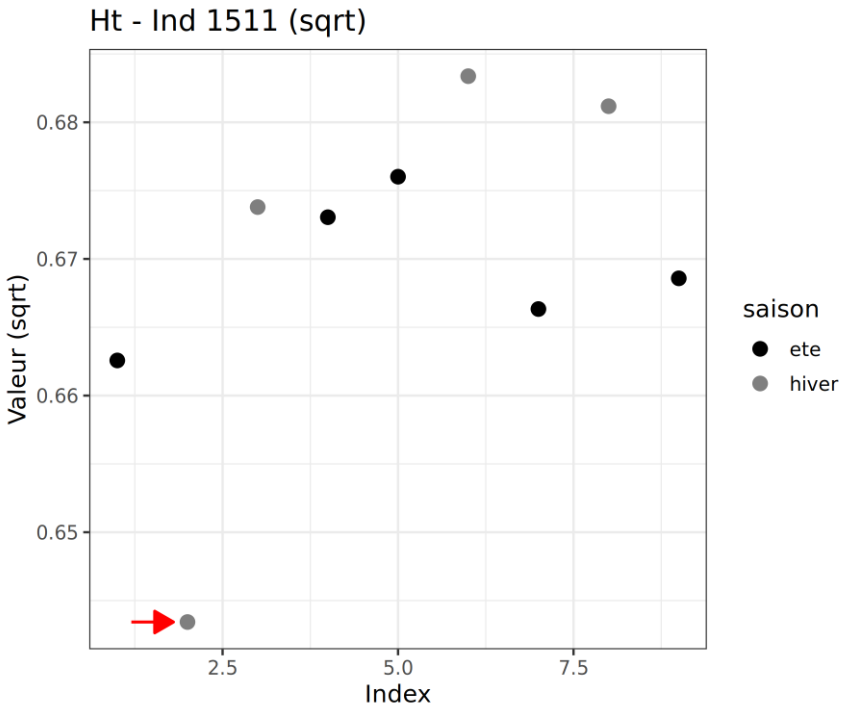

Figure 7 : Exemple de réalisation de DevianLM pour le modèle B

- **Modèle C** : Ce modèle prend en compte les **dates exactes des prélèvements**, permettant une analyse plus précise dans le temps. Il est appliqué uniquement à la base de données cyclisme, car celle du football ne contient pas la date du prélèvement. La formule du modèle est la suivante :

$$y = \beta_0 + \beta_1 . t + \varepsilon$$

β_0 : est l'intercept, il représente la valeur attendue du biomarqueur du sous-groupe (biomarqueur + individu) au temps t=0, soit à la date du premier prélèvement. Il sert de ligne de base individuelle du modèle.

β_1 : est le coefficient associé à la variable temporelle, indiquant l'effet du temps sur la séquence.
t: est une variable continue représentant le **temps** (par exemple, le nombre de jours depuis une date donnée).

Ce modèle est appliqué aux individus ayant **au moins 4 prélèvements** (car p=2), sans condition de répartition saisonnière **(Figure 8).**

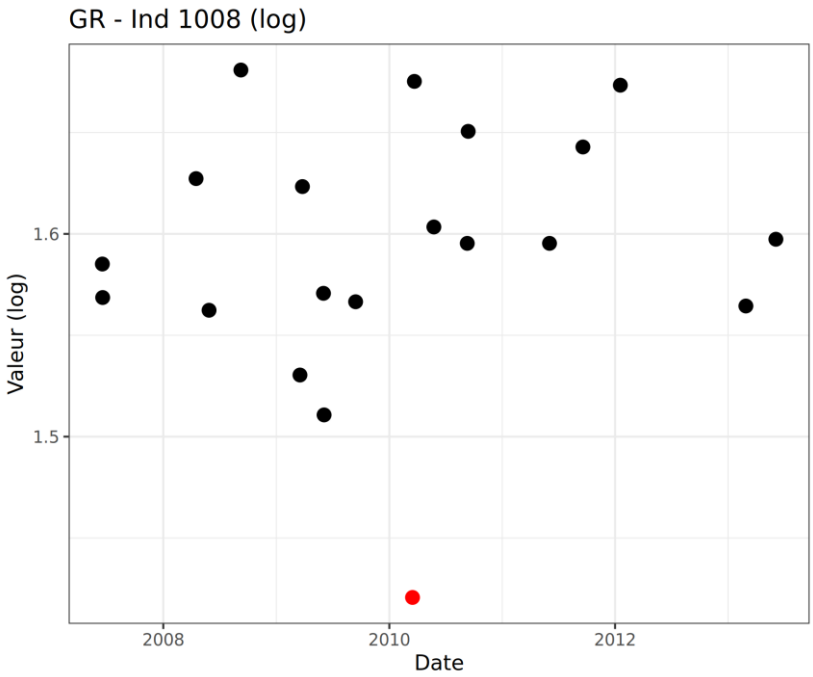

Figure 8 : Exemple de réalisation de DevianLM pour le modèle C

Une fois ces 3 modèles définis, j'ai appliqué le **package Devian-LM** pour détecter les anomalies dans les données biomédicales, en calculant les seuils de détection des anomalies à partir de la **statistique T_n**.

Le calcul des seuils s'est fait en utilisant des **simulations Monte Carlo**, qui permettent d'obtenir une estimation précise de la distribution de Tn. Pour ce faire, j'ai effectué **10^6 simulations**, ce qui permet d'obtenir des résultats fiables et d'ajuster dynamiquement les seuils.

Pour le **modèle A**, les seuils ont été calculés en fonction du **nombre de prélèvements** dans chaque séquence **(Figure 9).**

Ainsi, la statistique Tn a été estimée à partir des résidus studentisés externes, et le seuil de détection des anomalies a été ajusté en fonction de la taille de la séquence de données.

n	seuil_inf	seuil_sup
3	-38.2490	38.2490
4	-8.8642	8.8642
5	-5.8389	5.8389
6	-4.8511	4.8511
7	-4.3811	4.3811
41	-3.4877	3.4877
42	-3.4890	3.4890
43	-3.4908	3.4908
44	-3.4926	3.4926
45	-3.4949	3.4949

Figure 9 : Exemple de seuils obtenus en fonction du nombre de prélèvements

En revanche, pour les **modèles B et C**, où la détection devait être plus fine, le package a été appliqué individuellement pour chaque sportif, ce qui a permis de tenir compte des **différentes combinaisons de dates et de saisons**. Cette individualisation des seuils a permis d'obtenir des résultats plus précis, car chaque sportif a un seuil spécifique qui prend en compte la variabilité des dates de prélèvements et, dans le cas du modèle B, la distinction entre l'été et l'hiver.

Ces différences dans les approches de filtrage et de calcul des seuils ont permis d'adapter la détection des anomalies aux spécificités de chaque jeu de données. Par exemple, pour les individus ayant un nombre de prélèvements variable ou des périodes de prélèvement spécifiques, cette individualisation des seuils a assuré une détection plus précise. Les valeurs anormales ont été identifiées en comparant les résidus obtenus à un seuil calculé à partir du quantile à **5%** de la distribution de T_n.

Les méthodes de détection des anomalies, telles que **Z score** et **Devian-LM**, supposent une distribution **gaussienne** des données. Cependant, les données biomédicales peuvent ne pas suivre cette hypothèse. Afin de rendre les données compatibles avec ces méthodes, des **transformations ont été appliquées** sur certains biomarqueurs pour les rendre plus proches d'une distribution normale.

Les transformations ont été spécifiées pour chaque biomarqueur. Par exemple, pour les cyclistes, des transformations logarithmiques ont été appliquées à des biomarqueurs comme **GR** (globules rouges), **Reticulocytes**, **ReticulP**, **IGF1** et **Cortisol**. D'autres biomarqueurs tels que **Hb** (hémoglobine), **Ht** (hématocrite), et **Testosterone** ont été transformés à l'aide de la racine carrée, tandis que des biomarqueurs comme **HROFF** et **DHEA** ont été conservés dans leur format brut.
Pour les footballeurs, des transformations similaires ont été appliquées : **Hb**, **GR**, et **Ht** ont été transformés, respectivement, avec la racine carrée et le logarithme. En revanche, **Ferritine** et **Serum_iron** ont été log-transformés pour correspondre à une distribution plus normale.

Ces transformations ont été sélectionnées afin d'améliorer la normalité des données. En effet, certaines variables suivent une **distribution log-normale** (comme **Ferritine** et **IGF1**), ce qui justifie l'utilisation de transformations logarithmiques. D'autres variables comme **HROFF** n'ont pas nécessité de transformation et ont été laissées en **format brut**.

Bien que les transformations aient été fournies, il est à noter que, dans un cadre plus détaillé, un **test de Shapiro-Wilk** a permis de tester la normalité des données après chaque transformation [2]. En outre, un **test de Kolmogorov-Smirnov** a été utilisé pour vérifier l'adéquation des données transformées avec une loi uniforme, mais ces étapes n'ont pas été nécessaires dans le cadre de mon travail puisque les transformations étaient déjà définies.

[2] Saulière, G., Dedecker, J., Marquet, L. A., Rochcongar, P., Toussaint, J. F., & Berthelot, G. (2019). Z-scores-based methods and their application to biological monitoring: an example in professional soccer players. *Biostatistics*, *20*(1), 48-64.

Après l'application des différents modèles de détection d'anomalies, j'ai automatisé la **création d'un dossier de résultats** pour chaque modèle, afin de faciliter la gestion et l'interprétation des résultats. Chaque dossier contient des **figures générées pour visualiser les anomalies détectées,** enregistrées au format **PNG**. Ces graphiques permettent de visualiser clairement les **valeurs anormales** détectées pour chaque individu, en fonction des **biomarqueurs** et des transformations appliquées.

En complément, un **fichier CSV** a été généré pour chaque modèle, contenant les **numéros d'individus** et les **biomarqueurs** associés aux valeurs anormales détectées. Ce fichier centralise les résultats des anomalies, facilitant ainsi la communication et le partage des données avec les équipes médicales et les chercheurs.
Cette automatisation des figures et des fichiers CSV a permis de **gagner en efficacité** dans le traitement des données et de **rendre les résultats facilement exploitables**, tout en assurant une reproductibilité des analyses à grande échelle.

Enfin, pour vérifier la **fiabilité du modèle** et s'assurer qu'il détectait correctement les anomalies, j'ai créé des **modèles artificiels** en simulant des jeux de données directement à partir des lois normales où **aucun individu n'était anormal**. Ces simulations ont été réalisées pour chaque modèle, en générant des séries de données artificielles dans lesquelles toutes les valeurs des biomarqueurs étaient générées de manière aléatoire, sans aucun cas d'anomalie.
L'objectif était de tester si le modèle détectait bien les anomalies avec un **taux de faux positifs** conforme aux attentes, c'est-à-dire de s'assurer que le modèle ne signale pas d'anomalies là où il n'y en a pas. Pour ce faire, nous avons fixé un **paramètre de détection des anomalies** à **5%**, ce qui signifie que nous nous attendions à ce que **5% des observations** dans ces modèles artificiels soient identifiées comme des **faux outliers**.

Une fois ces modèles simulés et analysés, les résultats ont montré que, pour chaque modèle (A, B, C), le **taux de faux positifs était bien d'environ 5%**, confirmant ainsi la **validité** du seuil de détection des anomalies utilisé par le package **Devian-LM**. Ce test a permis de valider que les modèles fonctionnaient correctement et que les seuils de détection étaient bien calibrés pour garantir une précision optimale dans l'identification des anomalies réelles.

Par ailleurs, j'ai comparé les résultats des anomalies détectées par Devian-LM avec ceux issus des **méthodes Z score 1 et 2 [2]**, qui avaient été appliquées avant mon arrivée. Ces méthodes de référence étaient basées sur l'utilisation du **Z score**, un indicateur statistique permettant de mesurer l'écart d'une valeur par rapport à la moyenne en fonction de l'écart-type.

[2] Saulière, G., Dedecker, J., Marquet, L. A., Rochcongar, P., Toussaint, J. F., & Berthelot, G. (2019). Z-scores-based methods and their application to biological monitoring: an example in professional soccer players. *Biostatistics*, *20*(1), 48-64.

La méthode **Z score 1** repose sur le calcul d'un score statistique pour chaque observation individuelle. L'idée est de mesurer l'écart de chaque valeur observée par rapport à la moyenne de la séquence, normalisé par l'écart-type. La formule utilisée est la suivante [2] :

$$T_n = \max_{i \in \{1,\dots,n\}} \left| \frac{X_i - \overline{X}_{n,-i}}{\hat{\sigma}_{n,-i}\sqrt{1+\frac{1}{n-1}}} \right|$$

Où :

- $\boldsymbol{X_{I\ i}}$: valeur observée pour l'individu i,
- $\boldsymbol{\overline{X}_{n,-i}}$:: moyenne des valeurs du biomarqueur, excluant la valeur i,
- $\boldsymbol{\hat{\sigma}_{n,-i}}$:: écart-type des valeurs du biomarqueur, excluant Xi,
- $\boldsymbol{n}$: nombre d'observations dans la séquence.

Le modèle calcule un Z score pour chaque observation et détecte les valeurs anormales en prenant le **maximum** de ce Z score à travers l'ensemble des observations. Ce modèle est univarié, ce qui signifie qu'il analyse chaque biomarqueur indépendamment des autres.

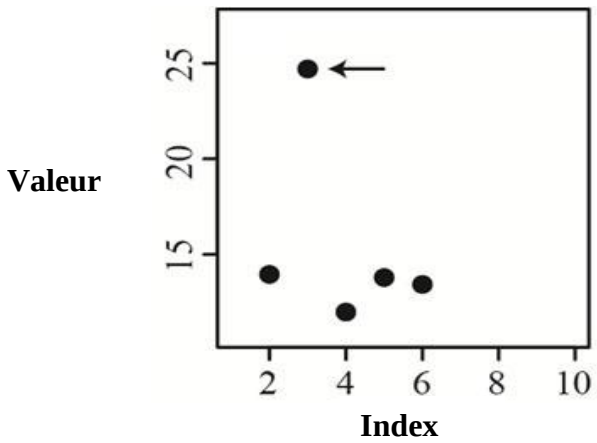

Figure 10 : Exemple de figure obtenue avec le Zscore 1

[2] Saulière, G., Dedecker, J., Marquet, L. A., Rochcongar, P., Toussaint, J. F., & Berthelot, G. (2019). Z-scores-based methods and their application to biological monitoring: an example in professional soccer players. *Biostatistics*, *20*(1), 48-64.

Quant à lui, le modèle **Z score 2** analyse les anomalies dans **une série de valeurs consécutives**, en prenant en compte non seulement les écarts individuels, mais aussi l'ordre et la succession des observations. Cette approche permet de mieux saisir les anomalies dans des suite de valeurs consécutives. La formule est la suivante [2] :

$$T_n = \max_I \left| \frac{X_I - \bar{X}_{\bar{I}}}{\hat{\sigma}_{n,I}\sqrt{\frac{1}{|I|} + \frac{1}{n-|I|}}} \right|$$

Où :
$\boldsymbol{X_I}$: valeur observée pour l'intervalle I dans la série de données,
$\bar{\boldsymbol{X}}_{\bar{I}}$: : moyenne des valeurs dans l'intervalle I,
$\hat{\boldsymbol{\sigma}}_{\boldsymbol{n,I}}$: écart-type des valeurs dans cet intervalle,

Dans ce modèle, **I** représente **tous les intervalles possibles** dans la séquence {1,…,n}. Cela signifie que chaque **sous-séquence** de valeurs consécutives (intervalle I) est considérée pour détecter des anomalies qui se répètent sur plusieurs observations successives.

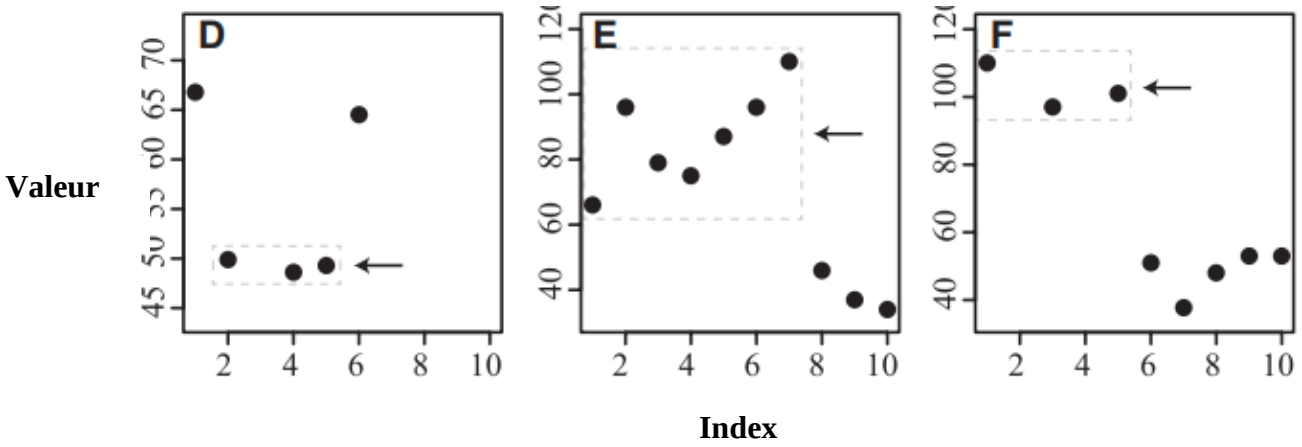

Figure 11 : Exemple de figures obtenues avec le Zscore 2

[2] Saulière, G., Dedecker, J., Marquet, L. A., Rochcongar, P., Toussaint, J. F., & Berthelot, G. (2019). Z-scores-based methods and their application to biological monitoring: an example in professional soccer players. *Biostatistics*, *20*(1), 48-64.

V.3. Résultats obtenus

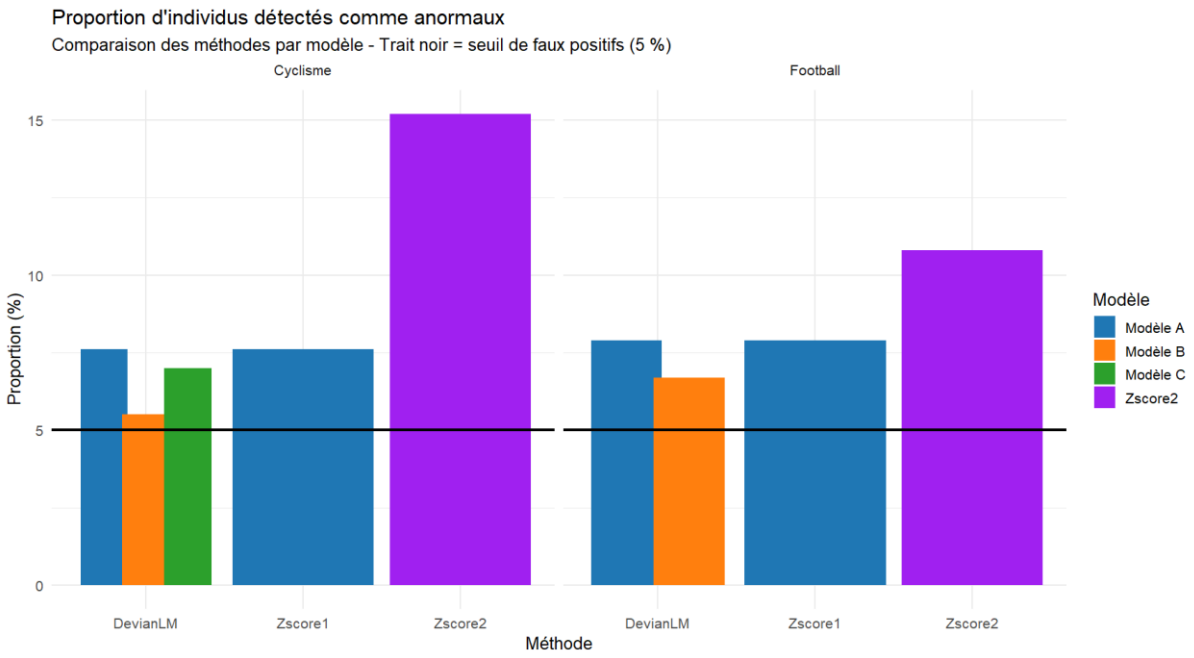

Figure 12 : Proportion d'individus anormaux détéctés pour chaque méthode.

La figure 10 montre la comparaison des méthodes **Zscore1**, **Zscore2**, et **DevianLM**, appliquées aux données des footballeurs et des cyclistes. Il met en évidence la proportion d'individus détectés comme anormaux par chaque méthode et illustre la différence entre les sports.

Les résultats montrent que **Zscore2** détecte un nombre beaucoup plus élevé d'individus anormaux, notamment pour le cyclisme, où plus de 15% des individus sont identifiés comme anormaux. Cela reflète une plus grande sensibilité de la méthode, capable de capter des anomalies liées à des ensembles de valeurs anormles.

En comparaison, les méthodes **DevianLM** et **Zscore1** détectent un nombre d'anomalies beaucoup plus faible, avec environ 7,5%.
Ces méthodes semblent équilibrer détection et précision, offrant ainsi un compromis entre sensibilité et spécificité. **DevianLM**, même dans sa version la plus simple (modèle A), confirme sa capacité à produire des résultats cohérents, identiques à ceux de **Zscore1**, ce qui valide son utilisation.

Les **modèles B et C**, quant à eux, montrent des résultats plusmodérés, détectant moins d'individus anormaux.
En conclusion, le **Zscore2** est utile pour une détection large des anomalies. Il convient maintenant de mener un travail d'investigation pour comprendre pourquoi le **Zscore2** détecte un plus grand nombre d'individus anormaux, en commençant par regarder qui sont les individus concernés. Il est possible que cette méthode mette en lumière des évènements (pathologies, entrainements en altitude, traitement médical, etc.) induisant un changement biologique prolongé, qui se traduisent par des valeurs de biomarqueurs loin de la ligne de base individuelle.

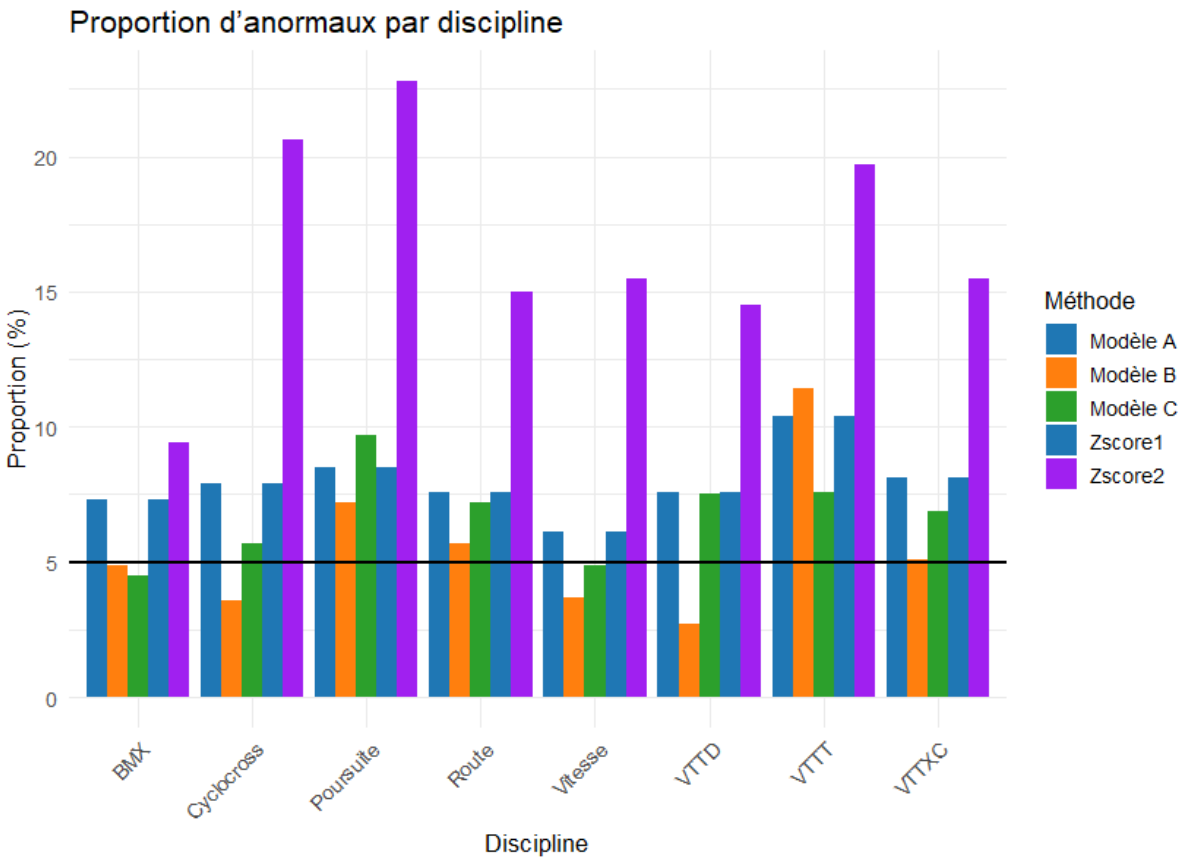

Figure 11 : Proportion de d'individus anormaux détéctés pour chaque méthode et pour chaque discipline (cyclisme uniquement).

(*) VTTD : VTT Downhill ; VTTXC : VTT Cross-Country ; VTTT : VTT Trail

La figure 11 met en évidence des différences dans la détection des anomalies selon les disciplines sportives, bien que celles-ci soient généralement légères. Cependant, des variations plus marquées apparaissent dans certaines disciplines comme la **poursuite**, et le **VTTT**, où la proportion d'individus détectés comme anormaux est plus élevée. Ces résultats pourraient s'expliquer par les spécificités physiologiques de ces sports, qui engendrent des variations biologiques plus marquées, susceptibles d'être interprétées comme des anomalies.
En revanche, les disciplines telles que le **BMX** ou la **route**, qui représente une part plus importante de la base de données (72,7% des athlètes pratiquent la **route**), présentent des proportions d'anomalies plus faibles.

Globalement, bien que les différences entre les disciplines ne soient pas toujours majeures, elles soulignent l'importance de prendre en compte les caractéristiques spécifiques de chaque sport. Cela permettra par la suite d'adapter les méthodes de détection en fonction des particularités de chaque discipline.

Les graphiques détaillant les résultats en fonction des variables contextuelles, telles que l'âge, le statut, détaillé par biomarqueur, sont disponibles en annexe (annexe 1).

IV.4. Conclusion technique

Pour conclure, le package **DevianLM**, utilisé lors de ce stage, peut s'appliquer de manière efficace à l'identification des **valeurs atypiques** dans divers contextes, qu'il s'agisse de détection d'anomalies liées à des problèmes de santé, de surmenage, ou encore de **dopage** dans le domaine sportif. Son utilisation pour le **suivi individualisé** des athlètes, à travers l'analyse des **biomarqueurs issus de prélèvements sanguins et urinaires**, permet une approche plus précise et personnalisée de la détection des anomalies. De plus, cette méthode est également applicable au suivi des **patients** dans un cadre médical, ce qui ouvre des perspectives d'utilisation dans de nombreux domaines liés à la **santé**.

Les perspectives d'avenir pour DevianLM incluent son extension vers des **analyses multivariées**, ce qui élargirait ses capacités en permettant de traiter des données plus complexes et de mieux prendre en compte les interactions entre différentes **variables**. Cette polyvalence fait de ce package un **outil précieux** pour des recherches futures, tant dans le domaine **médical** que sportif.

Toutefois, au-delà de la théorie et des perspectives d'application, plusieurs **défis techniques** ont marqué le déroulement de ma mission. La gestion et le traitement des données ont nécessité une attention particulière, notamment lors du **filtrage** des données et du traitement des **valeurs manquantes**. Assurer la cohérence des **séries temporelles** pour chaque individu était crucial pour garantir la fiabilité des analyses.

Une autre difficulté résidait dans l'utilisation du package, qui ne propose pas de **transformations automatiques** des données. J'ai donc dû appliquer moi-même les transformations nécessaires (**logarithme**, **racine carrée**) afin d'ajuster les données aux **distributions normales**, conformément aux hypothèses des tests statistiques
.
Enfin, l'ajustement des **seuils de détection** des anomalies, effectué à l'aide de **simulations Monte Carlo**, a été un point clé du stage. Trouver le bon compromis entre **sensibilité** et **précision** pour éviter les **faux positifs** était un véritable enjeu. Cette expérience m'a permis de mieux comprendre l'importance de calibrer les modèles en fonction des spécificités des **données**, afin d'assurer des résultats pertinents et fiables.

En résumé, ce travail m'a permis de renforcer mes compétences en **gestion des données**, en **modélisation statistique** et en **validation des résultats**, tout en m'apprenant à m'adapter aux défis techniques rencontrés, afin de mener à bien l'analyse.

V. Conclusion générale

Ce stage à l'INSEP a été une expérience enrichissante qui m'a permis d'allier mes compétences en **data science** à ma passion pour le sport, tout en découvrant de nouveaux horizons, notamment dans le domaine de la **biostatistique** appliquée à la performance sportive. Travailler sur des **données biomédicales** de footballeurs et de cyclistes m'a permis de développer des compétences techniques solides en **programmation R** et en modélisation statistique.

Au-delà des aspects techniques, ce stage m'a aussi permis d'approfondir mes connaissances sur la **vision par ordinateur**, un domaine abordé par un autre stagiaire avec lequel j'ai eu l'occasion d'échanger régulièrement. Bien que ce ne fût pas mon sujet initial, nos échanges m'ont ouvert à de nouvelles perspectives et m'ont permis de mieux comprendre l'impact de la vision par ordinateur dans le suivi de la performance athlétique. Ces échanges ont élargi ma réflexion et renforcé mon désir d'explorer des domaines croisés entre **data science** et autres technologies innovantes.

Les relations de travail au sein de l'INSEP ont été très formatrices. J'ai particulièrement apprécié la collaboration avec mon tuteur, Geoffroy Berthelot, qui m'a soutenu tout au long du stage, tout en me donnant une grande autonomie dans l'exécution de mes missions. Les échanges avec lui, mais aussi avec d'autres membres de l'équipe et le stagiaire, m'ont permis de mieux comprendre l'importance du travail en équipe et des retours constructifs dans un environnement professionnel.

Ce type d'entreprise, à la fois innovant et orienté vers la performance de haut niveau, me correspond pleinement et confirme mon envie de travailler dans ce secteur où **data science** et **sport** se rencontrent. À l'avenir, je compte poursuivre mes études à l'**ENSAI**, dans le cadre d'un **double diplôme en sciences et numériques du sport**, et ce stage s'inscrit parfaitement dans mon projet professionnel. Il a renforcé mon désir de lier mes compétences techniques au domaine sportif, en travaillant sur des problématiques concrètes et complexes.

En résumé, cette expérience à l'INSEP m'a permis non seulement de développer des compétences techniques et pratiques en **data science** et en **biostatistique**, mais aussi d'affiner mes perspectives professionnelles en découvrant de nouvelles applications de ces domaines, et en renforçant ma volonté de poursuivre dans cette voie passionnante.

VI. Bibliographie

Sources des photographies :

(1) : Vue aérienne Insep : https://resize-europe1.lanmedia.fr/r/622,311,forcex,center-middle/img/var/europe1/storage/images/europe1/sport/a-quelques-jours-des-jo-de-paris-2024-200-athletes-francais-se-preparent-dans-un-insep-transforme-en-camp-de-base-4257039/61792512-1-fre-FR/A-quelques-jours-des-JO-de-Paris-2024-200-athletes-francais-se-preparent-dans-un-INSEP-transforme-en-camp-de-base.jpg

(2) : Photographie du batiment de l'INSEP : Des athlètes français logeront à l'Insep pendant les JO 2024, L'Equipe, 2024

Sources des articles :

[1] Pour DevianLM :

Berthelot G., Saulière, G., Dedecker, J. DEViaN-LM: An R Package for Detecting Abnormal Values in the Gaussian Linear Model.

[2] Pour le Zscore 1 et 2 :

Saulière, G., Dedecker, J., Marquet, L. A., Rochcongar, P., Toussaint, J. F., & Berthelot, G. (2019). Z-scores-based methods and their application to biological monitoring: an example in professional soccer players. *Biostatistics*, *20*(1), 48-64.

VII. Lexique

ANOMALIE (valeur anormale)
Valeur qui s'écarte significativement d'un comportement attendu. Peut signaler une pathologie, un surmenage ou un dopage potentiel.

BIOMARQUEUR
Indicateur biologique mesurable dans un fluide corporel (ex. sang) servant à suivre la santé ou la performance (ex. : cortisol, ferritine, etc.).

BMX
Discipline cycliste de type "Bicycle Moto Cross", orientée sprint et figures, pratiquée sur une piste courte.

CORTISOL
Hormone du stress, surveillée car ses variations peuvent révéler une fatigue ou une réponse au surmenage.

CSV (.csv)
Fichier texte contenant des données sous forme de tableau, chaque valeur étant séparée par une virgule.

DÉTECTION (des anomalies)
Processus statistique consistant à identifier les observations qui dévient des tendances normales.

DHEA (Déhydroépiandrostérone)
Hormone produite par les glandes surrénales, souvent liée à la performance, au stress et à l'âge.

DISCIPLINE (cyclisme)
Sous-catégorie sportive au sein du cyclisme : route, VTT, BMX, etc., chacune avec ses spécificités physiologiques.

DEVIAN-LM
Package R développé à l'INSEP pour détecter des séquences anormales dans des séries temporelles de données biologiques.

ÉCHANTILLON
Sous-ensemble de données utilisé pour représenter une population plus large.

ÉCART-TYPE
Mesure de la dispersion d'une série de valeurs autour de leur moyenne.

FER (sérique)
Quantité de fer circulant librement dans le sang, utilisée pour évaluer l'état nutritionnel ou détecter certaines pathologies.

FERRITINE
Protéine stockant le fer dans l'organisme, reflet des réserves en fer.

G/L (Giga par litre)
Unité utilisée pour compter des cellules sanguines, comme les réticulocytes (1 G/L = 1 milliard/L).

GAUSSIEN (modèle)
Modèle statistique basé sur la loi normale, avec une courbe en cloche symétrique.

GGPlot2, DPLYR, READR, etc.
Bibliothèques (packages) R utilisées pour la visualisation, la manipulation ou l'importation de données.

GR (Globules Rouges)
Cellules sanguines transportant l'oxygène. Leur taux est un indicateur clé de performance et de santé.

HÉMATOCRITE (Ht)
Pourcentage de volume sanguin occupé par les globules rouges. Peut refléter la capacité d'endurance.

HÉMOGLOBINE (Hb)
Protéine des globules rouges qui transporte l'oxygène. Mesurée en grammes par litre.

IGF1 (Insulin-like Growth Factor 1)
Facteur de croissance lié à l'hormone de croissance, suivi dans les contrôles antidopage.

INTERCEPT
Constante d'un modèle linéaire représentant la valeur moyenne prédite quand toutes les variables sont nulles.

LIGNE DE BASE
Valeur de référence pour un biomarqueur, propre à un individu. Sert à identifier les écarts anormaux.

LOI NORMALE
Distribution en forme de cloche symétrique, utilisée dans de nombreux modèles statistiques.

MONTE CARLO (simulations)
Technique de simulation basée sur le hasard, utilisée pour estimer des seuils statistiques.

NG/mL, NMOL/L, µMOL/L
Unités de concentration : nanogrammes, nanomoles ou micromoles par litre. Utilisées pour mesurer les biomarqueurs.

OFF-SCORE (HROFF)
Indice composite sans unité, utilisé pour détecter les manipulations sanguines (ex. : dopage).

PACKAGE (R)
Ensemble de fonctions regroupées dans R, facilitant des tâches spécifiques (comme Devian-LM pour la détection d'anomalies).

R / RSTUDIO
Environnement de programmation et d'analyse statistique utilisé tout au long du stage.

RACINE CARRÉE / LOGARITHME
Transformations mathématiques appliquées aux données pour les rendre plus normales (gaussiennes).

RÉSIDU (studentisé)
Différence entre une valeur observée et sa valeur prédite par le modèle, utilisée pour détecter des anomalies.

RÉTICULOCYTES / RETICULP
Globules rouges immatures, indicateurs du renouvellement sanguin.

SEUIL (statistique)
Valeur limite utilisée pour déterminer si une observation est considérée comme anormale.

STATISTIQUE Tn
Mesure issue de Devian-LM utilisée pour juger si l'ensemble d'une séquence est anormal.

TEST DE KOLMOGOROV-SMIRNOV / SHAPIRO-WILK
Tests statistiques servant à vérifier si une variable suit une distribution donnée (ex. : normale ou uniforme).

TRANSFORMATION (des données)
Modification mathématique (ex. logarithme) appliquée pour respecter les conditions des modèles statistiques.

VTTD, VTTXC, VTTT
Sous-disciplines du VTT :

- **VTTD** : Downhill (descente)
- **VTTXC** : Cross-Country
- **VTTT** : Trail ou toutes-terrains

Z-SCORE
Indicateur exprimant à combien d'écarts-types une valeur s'éloigne de la moyenne. Utilisé pour détecter des valeurs extrêmes.

VIII. Annexes

Annexe 1 : Proportion d'individus anormaux selon les différentes variables contextuelles, détaillé par biomarqueur

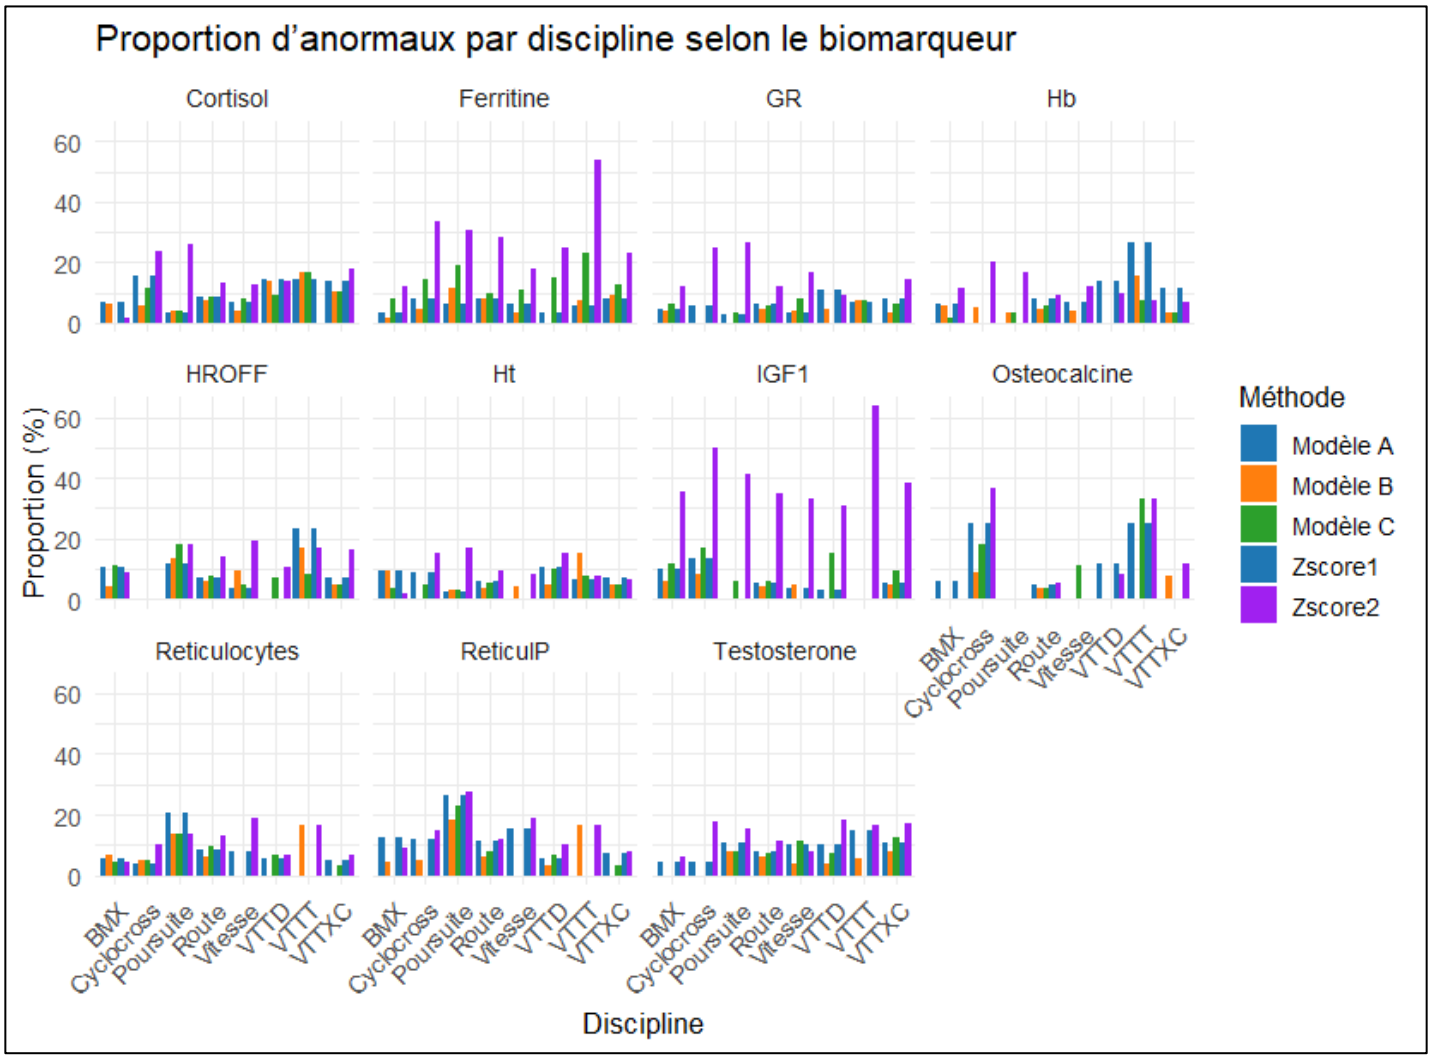

Auteur : Arthur SIMON
Date : 18/06/2025

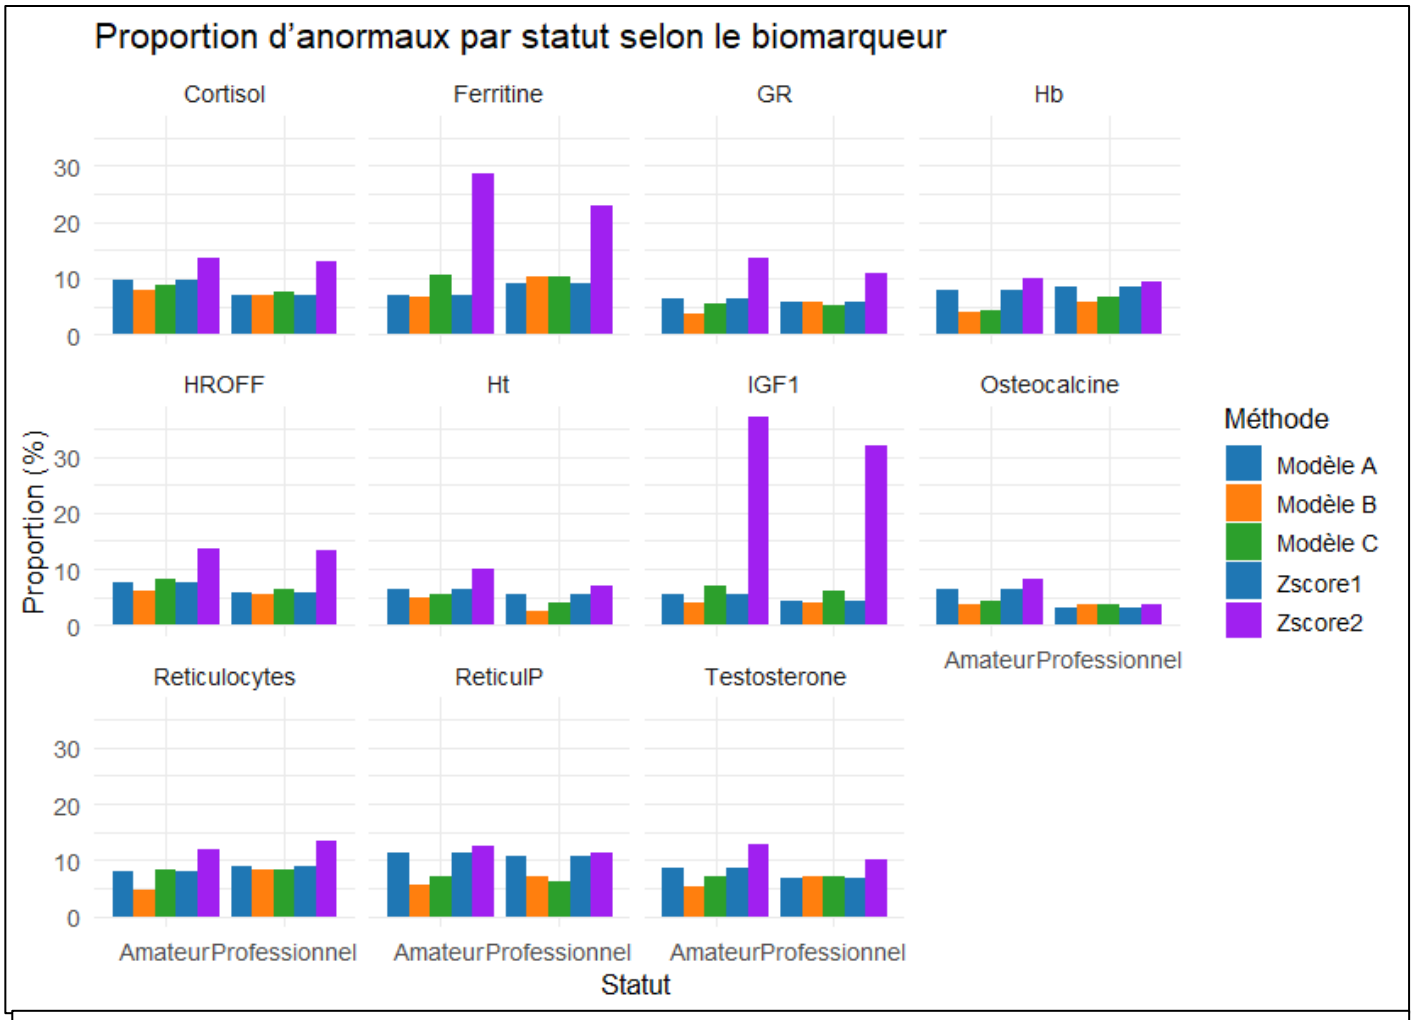

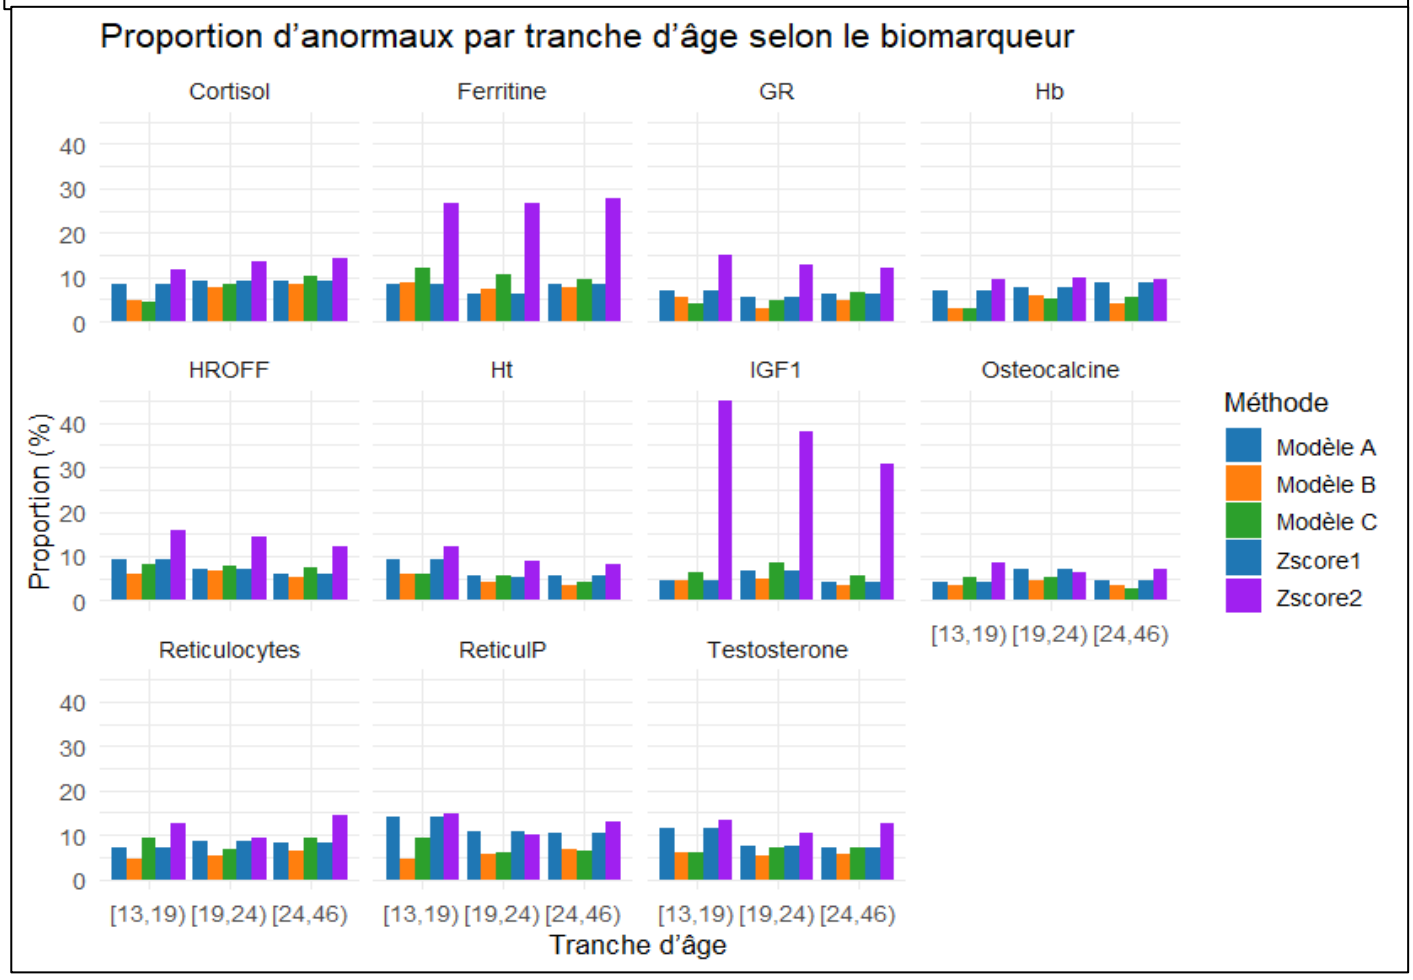

IX. Démarche portfolio

Traiter des données à des fins décisionnelles

Mon stage m'a permis de renforcer ma capacité à structurer et préparer des données dans un but décisionnel. J'ai appris à manipuler des données médicales complexes, provenant de différentes sources (football et cyclisme), et à les rendre exploitables pour des analyses spécifiques. Ce travail m'a montré qu'un traitement rigoureux et méthodique est indispensable pour garantir la fiabilité des analyses et des décisions qui en découlent. De plus, en utilisant **R** pour traiter et analyser les données, j'ai vraiment progressé dans la **programmation** et la gestion des grandes séries de données.

En effectuant ce travail, j'ai pris conscience que l'alignement des données avec les objectifs du projet est un facteur clé. Par exemple, en structurant les données en fonction du type de sport et des prélèvements, j'ai pu appliquer les modèles statistiques de manière pertinente, garantissant que les résultats seraient utilisables pour des décisions concrètes. Cette expérience m'a également permis de mieux comprendre **comment fonctionne un package R** et comment l'utiliser de manière efficace pour **réaliser des analyses adaptées**. Cela m'a montré qu'une mauvaise gestion des données peut fausser toute analyse.

Cette compréhension m'a permis de mieux appréhender l'importance de l'adaptation des méthodes aux contextes spécifiques. À l'avenir, je serai plus attentif à la préparation des données pour garantir des résultats pertinents et des décisions fiables, tout en sachant exploiter pleinement les outils comme **R** pour automatiser et affiner les processus d'analyse.

Analyser statistiquement des données | Modéliser les données dans un cadre statistique

L'analyse statistique a constitué un élément majeur de ma mission, en particulier lorsqu'il s'est agi de **modéliser des données complexes** issues de prélèvements de biomarqueurs. L'utilisation de **modèles statistiques** et de **lois aléatoires**, combinée à des **matrices de design**, m'a permis de traiter efficacement des séries longitudinales. Cette expérience m'a permis de **mettre en application** des concepts théoriques, comme ceux abordés en cours, tout en les adaptant à un **contexte professionnel concret**. Modéliser les données à l'aide de **R** m'a permis de renforcer mes compétences dans le **traitement de données complexes** et de mieux comprendre l'importance de **normaliser** les données pour en assurer la **fiabilité**.

Ce travail m'a fait réaliser que les **méthodes statistiques** ne sont pas simplement des outils à appliquer mécaniquement, mais qu'elles doivent être **adaptées aux spécificités des données** pour produire des résultats pertinents. Par exemple, l'utilisation de **modèles linéaires** a été essentielle pour comprendre comment ajuster les outils statistiques en fonction des **objectifs du projet**, tout en tenant compte des caractéristiques propres aux séries de données longitudinales. Cela m'a aussi révélé qu'une analyse doit être accompagnée de **validations rigoureuses** pour tester sa **pertinence** et garantir que les résultats obtenus sont **robustes** et **fiables**.

En réinvestissant cet apprentissage, je serai désormais plus vigilant à **sélectionner et ajuster les modèles statistiques** selon les caractéristiques des données disponibles. L'expérience m'a montré l'importance d'**adapter les méthodes** pour qu'elles soient non seulement plus **précises**,

mais aussi plus **efficaces** et **pertinentes**. Je vais pouvoir réinvestir cette approche dans de futures analyses, en mettant l'accent sur **l'adaptabilité des outils statistiques** aux **besoins spécifiques du projet**.

Valoriser une production dans un contexte professionnel

Au cours de ce stage, une des compétences clés que j'ai renforcées a été la capacité à **valoriser les résultats** d'analyses dans un cadre professionnel. Travailler avec des experts médicaux et sportifs m'a permis de **comprendre l'importance d'adapter la présentation des résultats** afin qu'ils soient à la fois **clairs** et **utilisables** par des personnes non spécialisées. Cette expérience m'a appris à utiliser des **visualisations efficaces** et des **résumés concis** pour faciliter la prise de décision.

Cependant, un aspect particulièrement important a été de **lire les comptes rendus précédemment rédigés** et **les articles scientifiques en anglais** fournis par l'équipe. Cela m'a permis de mieux comprendre les enjeux sous-jacents et de m'assurer que mes conclusions étaient bien en phase avec les attentes et la **terminologie spécifique** utilisée dans le milieu professionnel.
Le **déclic** pour moi a été de réaliser que la **précision des résultats** ne suffit pas : il faut aussi savoir **adapter le message** en fonction de l'audience. La lecture des documents antérieurs m'a permis de saisir **les attentes spécifiques** des experts et de mieux comprendre leurs préoccupations, ce qui m'a aidé à **ajuster ma communication** et à présenter les résultats de manière plus **pertinente**.

En réinvestissant cette expérience, je serai désormais plus attentif à **adapter mes écrits et présentations** en fonction des **références existantes** et des **besoins des professionnels**, afin de garantir que mes analyses aient un **impact direct** et **utile** dans la prise de décision.

Savoir-faire

Ce stage a été ma première expérience dans le domaine de la **data**, et cela a confirmé ma volonté de poursuivre ma carrière dans ce secteur. Travailler dans un environnement professionnel m'a appris à m'organiser efficacement, à **respecter les délais** et à être **réactif** en cas de besoin. Bien que j'aie travaillé de manière autonome, j'ai pu compter sur mon maître de stage pour poser des questions à tout moment, ce qui a renforcé l'importance de la **communication claire et fluide**.

Ce que j'ai réalisé, c'est que l'autonomie ne se résume pas uniquement à être capable de travailler seul, mais à savoir quand et comment solliciter de l'aide pour **avancer plus efficacement**. Cette expérience m'a aussi montré qu'une **bonne organisation** et une **communication constante** sont essentielles pour réussir dans un environnement professionnel. Je vais réinvestir cette expérience dans mes futures missions, en restant attentif à **l'adaptabilité** et à la **collaboration**, tout en continuant à affiner mes méthodes pour être plus **productif** et **réactif**.